

UNIVERSIDAD DE GUADALAJARA

Centro Universitario de Ciencias Económico
Administrativas (CUCEA)

Estadística I

Proyecto Final de Estadística

Análisis Estadístico de Proyecciones de Población de la
República Checa

Alumna: Frida Suárez De Luna

Profesor: Rigoberto Silva Robles

Fecha: Mayo 2026

Índice

1. Introducción
2. Medidas de Tendencia Central
3. Medidas de Dispersión
4. Introducción a Probabilidad
5. Distribución de Probabilidad con VAD
6. Distribución de Probabilidad con VAC
7. Datos Agrupados
8. Datos No Agrupados
9. Rango
10. Rango Intercuartílico
11. Varianza
12. Desviación Estándar
13. Desviación Media
14. Diagrama de Venn
15. Conteo
16. Combinación
17. Permutación
18. Probabilidad Condicional
19. Teorema de Bayes
20. Distribución Binomial
21. Distribución Poisson
22. Distribución Hipergeométrica
23. Distribución Normal
24. Distribución Normal Estándar
25. Índice Paasche
26. Índice Laspeyres
27. Índice Fisher

✓ Introducción

En este proyecto se realizó un análisis estadístico de datos poblacionales correspondientes a la República Checa.

Para el desarrollo del trabajo se utilizó Python como herramienta principal para procesar los datos, realizar cálculos estadísticos y generar gráficas que facilitan la interpretación de la información.

El objetivo fue aplicar los temas vistos en la materia de Estadística I, incluyendo medidas de tendencia central, medidas de dispersión, probabilidad, distribuciones de probabilidad e índices estadísticos.

Los datos fueron previamente limpiados y organizados para garantizar resultados correctos, y posteriormente se analizaron mediante distintos métodos matemáticos y gráficos.

```
from google.colab import files
uploaded = files.upload()
```

Seleccionar archivos  datos_limpi...xSOLO.xlsx

datos_limpios.xlsxSOLO.xlsx(application/vnd.openxmlformats-officedocument.spreadsheetml.sheet) - 97314 bytes, last modified: n/a - 100% done
Saving datos_limpios.xlsxSOLO.xlsx to datos_limpios.xlsxSOLO.xlsx

✓ Carga y limpieza de datos

En esta sección se cargó el archivo de Excel con los datos poblacionales de la República Checa.

Primero se identificó la fila donde comienza la tabla real. Después se eliminaron filas vacías, columnas innecesarias y se convirtieron los datos a valores numéricos.

Este proceso es importante porque permite trabajar con una base limpia y organizada para realizar correctamente los cálculos estadísticos.

Interpretación:

Después de limpiar los datos, la tabla quedó organizada por grupos de edad y por años.

Esto permite utilizar la columna 2023 como base principal para calcular las medidas estadísticas del proyecto.

```
import pandas as pd

# nombre del archivo
archivo = "datos_limpios.xlsxSOL0.xlsx"

# leer hoja sin formato
df_raw = pd.read_excel(archivo, sheet_name="Table", header=None)

# detectar dónde empieza la tabla
fila_inicio = None

for i, row in df_raw.iterrows():
    if row.astype(str).str.contains("Age", case=False, na=False).any():
        fila_inicio = i
        break

print("Fila donde empieza la tabla:", fila_inicio)

# leer datos reales
df = pd.read_excel(archivo, sheet_name="Table", skiprows=fila_inicio)

# renombrar columna
df.rename(columns={df.columns[1]: "Edad"}, inplace=True)

# eliminar filas vacías
df = df[df["Edad"].notna()]

# eliminar filas basura
df = df[~df["Edad"].astype(str).str.contains("Sex", na=False)]

df = df.reset_index(drop=True)

# crear columnas de años
años = list(range(2023, 2023 + len(df.columns) - 3))
df.columns = ["col0", "Edad", "col2"] + [str(a) for a in años]

# eliminar columnas basura
df = df.drop(columns=["col0", "col2"])
```

```
# convertir a numeros
for col in df.columns[1:]:
    df[col] = pd.to_numeric(df[col], errors="coerce")

df = df.dropna(subset=["2023"])

print("\nDATOS LIMPIOS:")
print(df.head())
```

Fila donde empieza la tabla: 7

DATOS LIMPIOS:

	Edad	2023	2024	2025	2026
0	Total	5642582.0	5616621.0	5591121.0	5565887.0
1	4 years or less	276925.0	271896.0	265682.0	260892.0
2	From 5 to 9 years	296542.0	293260.0	290350.0	285252.0
3	From 10 to 14 years	296486.0	290988.0	288472.0	288501.0
4	From 15 to 19 years	295161.0	302179.0	304754.0	302408.0

	2028	2029	2030	2031	...	2061
0	5518633.0	5496571.0	5475129.0	5454403.0	...	5307768.0
1	252879.0	248629.0	245206.0	242644.0	...	242273.0
2	274147.0	270544.0	265450.0	261567.0	...	253852.0
3	289033.0	286986.0	285264.0	281258.0	...	264003.0
4	289833.0	285292.0	283538.0	284326.0	...	270115.0

	2063	2064	2065	2066	2067	2068
0	5288204.0	5277940.0	5267526.0	5257096.0	5246787.0	5236732.0
1	240654.0	240284.0	240202.0	240385.0	240801.0	241406.0
2	250251.0	248620.0	247178.0	245969.0	245031.0	244385.0
3	260925.0	259186.0	257375.0	255531.0	253707.0	251960.0
4	269583.0	268865.0	267868.0	266633.0	265191.0	263583.0

	2069	2070
0	5227124.0	NaN
1	242158.0	NaN
2	244036.0	NaN
3	250348.0	NaN
4	261863.0	NaN

[5 rows x 49 columns]

✓ Medidas de Tendencia Central

Las medidas de tendencia central permiten identificar valores representativos dentro de un conjunto de datos.

En este proyecto se calcularon:

- Media
- Mediana
- Moda

Estas medidas ayudan a entender el comportamiento general de la población.

```
import matplotlib.pyplot as plt

print("\n=====")
print("MEDIDAS DE TENDENCIA CENTRAL")
print("=====")

# datos del año 2023
edades = df["2023"]

# -----
# MEDIA
# -----
media = edades.mean()
print("\nMEDIA:", media)

# -----
# MEDIANA
# -----
mediana = edades.median()
print("MEDIANA:", mediana)

# -----
# MODA
# -----
moda = edades.mode()[0]
print("MODA:", moda)

# -----
# GRÁFICA
# -----
plt.figure(figsize=(8,5))
```

```
nombres = ["Media", "Mediana", "Moda"]
valores = [media, mediana, moda]


plt.bar(nombres, valores)

plt.title("Medidas de Tendencia Central")
plt.ylabel("Valores")

plt.savefig("tendencia_central.png")
plt.show()
```

```
=====
MEDIDAS DE TENDENCIA CENTRAL
=====
```

```
MEDIA: 1236097.1666666667
MEDIANA: 437400.0
MODA: 62698.0
```



Interpretación:

La media fue aproximadamente 1,236,097, la mediana 437,400 y la moda 62,698.

La media es mayor que la mediana, lo que indica que existen valores altos que elevan el promedio.

La gráfica permite comparar visualmente estas tres medidas.

✓ Medidas de Dispersión

Las medidas de dispersión permiten conocer qué tan separados están los datos respecto a un valor central.

En este análisis se calcularon:

- Rango
- Rango intercuartílico
- Varianza
- Desviación estándar
- Desviación media

Además, se utilizaron gráficas como el histograma y el boxplot para visualizar la distribución de los datos.

```
print("\n=====")
print("MEDIDAS DE DISPERSIÓN")
print("=====")

# -----
# RANGO
# -----
rango = edades.max() - edades.min()
print("\nRANGO:", rango)

# -----
# RANGO INTERCUARTÍLICO
# -----
Q1 = edades.quantile(0.25)
Q3 = edades.quantile(0.75)
RIC = Q3 - Q1

print("RANGO INTERCUARTÍLICO:", RIC)
```

```
# -----
# VARIANZA
# -----
varianza = edades.var()
print("VARIANZA:", varianza)

# -----
# DESVIACIÓN ESTÁNDAR
# -----
desv = edades.std()
print("DESVIACIÓN ESTÁNDAR:", desv)

# -----
# DESVIACIÓN MEDIA
# -----
desv_media = abs(edades - edades.mean()).mean()
print("DESVIACIÓN MEDIA:", desv_media)

# =====
# GRÁFICA HISTOGRAMA
# =====
import matplotlib.pyplot as plt

plt.figure(figsize=(8,5))

plt.hist(edades, bins=10)

plt.title("Distribución de la población")
plt.xlabel("Valores")
plt.ylabel("Frecuencia")

plt.savefig("histograma.png")
plt.show()

# =====
# GRÁFICA BOXPLOT
# =====

plt.figure(figsize=(6,4))

plt.boxplot(edades)

plt.title("Dispersión de datos")

plt.savefig("boxplot.png")
plt.show()
```

=====

MEDIDAS DE DISPERSIÓN

=====

RANGO: 10970708.0


RANGO INTERCUARTÍLICO: 641764.5

VARIANZA: 3718297922790.282


DESVIACIÓN ESTÁNDAR: 1928288.8587528276

DESVIACIÓN MEDIA: 1251769.5416666667

Distribución de la población



Dispersión de datos



1

Interpretación:

El rango obtenido muestra que existe una gran diferencia entre los valores mínimos y máximos.

La varianza y la desviación estándar son altas, lo que indica que los datos están muy dispersos.

El histograma permite observar la distribución de la población, mientras que el boxplot muestra la variabilidad y posibles valores extremos.

✓ Probabilidad

La probabilidad permite medir la posibilidad de que ocurra un evento.

En este proyecto se analizó la probabilidad de seleccionar personas pertenecientes a ciertos grupos de edad dentro de la población total.

Se calcularon:

- Probabilidad básica
- Probabilidad condicional
- Teorema de Bayes

```
print("\n=====")
print("PROBABILIDAD")
print("=====")

# total población
total_2023 = df[df["Edad"] == "Total"] ["2023"].values[0]

# menores de 4
menores_4 = df[df["Edad"] == "4 years or less"] ["2023"].values[0]

# -----
# PROBABILIDAD BÁSICA
# -----
```

```

P_A = menores_4 / total_2023

print("\nPROBABILIDAD BÁSICA P(A):", P_A)

# -----
# PROBABILIDAD CONDICIONAL
# -----
menores_10 = df[df["Edad"].isin([
    "4 years or less",
    "From 5 to 9 years"
])]["2023"].sum()

P_B = menores_10 / total_2023
P_A_dado_B = P_A / P_B

print("\nP(B):", P_B)
print("P(A|B):", P_A_dado_B)

# -----
# TEOREMA DE BAYES
# -----
print("\nTEOREMA DE BAYES:", P_A_dado_B)

# =====
# GRÁFICA DE PROBABILIDAD
# =====

import matplotlib.pyplot as plt

plt.figure(figsize=(6,4))

nombres = ["P(A)", "P(B)"]
valores = [P_A, P_B]

plt.bar(nombres, valores)

plt.title("Probabilidades")

plt.savefig("probabilidades.png")
plt.show()

```

```

=====
PROBABILIDAD
=====

```


```

PROBABILIDAD BÁSICA P(A): 0.04907770945996

```

$P(B) : 0.41664223931526384$
 $P(A|B) : 0.11779340841825688$

TEOREMA DE BAYES: 0.11779340841825688



Interpretación:

La probabilidad básica indica la proporción de personas menores de 4 años dentro de la población total.

La probabilidad condicional permite analizar la relación entre los grupos de edad, en este caso entre menores de 4 años y menores de 10 años.

El teorema de Bayes ayuda a interpretar estas probabilidades considerando información previa, mostrando que aproximadamente el 11.77% del grupo de menores de 10 años corresponde a personas de 4 años o menos.

✓ Distribuciones de Probabilidad

Las distribuciones de probabilidad permiten modelar el comportamiento de los datos en distintos escenarios.

En este proyecto se aplicaron:

- Distribución binomial
- Distribución Poisson
- Distribución hipergeométrica
- Distribución normal

Cada una de estas distribuciones ayuda a analizar diferentes tipos de eventos dentro de la población.

```
import math
from scipy.stats import hypergeom, norm
import numpy as np
import matplotlib.pyplot as plt

print("\n=====")
print("DISTRIBUCIONES")
print("=====")

# -----
# BINOMIAL
# -----
p = P_B
n = 1000
k = int(n * p)

binomial = math.comb(n, k) * (p ** k) * ((1 - p) ** (n - k))

print("\nBINOMIAL:", binomial)

# -----
# POISSON
# -----
lambda_ = P_A
k_poisson = 1

poisson = math.exp(-lambda_) * (lambda_ ** k_poisson) / math.factorial(k_poisson)

print("POISSON:", poisson)
```

```

# -----
# HIPERGEOMÉTRICA
# -----
N = int(total_2023)
K = int(menores_4)
n_hiper = 1000
x = 50

hiper = hypergeom.pmf(x, N, K, n_hiper)

print("HIPERGEOMÉTRICA:", hiper)

# -----
# DISTRIBUCIÓN NORMAL
# -----
mu = edades.mean()
sigma = edades.std()

x_vals = np.linspace(edades.min(), edades.max(), 100)
y_vals = norm.pdf(x_vals, mu, sigma)

plt.figure(figsize=(8,5))
plt.plot(x_vals, y_vals)

plt.title("Distribución Normal")
plt.xlabel("Valores")
plt.ylabel("Densidad")

plt.savefig("distribucion_normal.png")
plt.show()

# -----
# NORMAL ESTÁNDAR (Z)
# -----
x_z = 500000
z = (x_z - mu) / sigma

print("\nZ:", z)

```

```

=====
DISTRIBUCIONES
=====

```


```

BINOMIAL: 0.025566756438429688
POISSON: 0.046727237547113554
HIPERGEOMÉTRICA: 0.0572718809353194

```

1e-7

Distribución Normal



z: -0.38173594341190004

Interpretación:

La distribución binomial permite calcular la probabilidad de obtener un número específico de casos dentro de una muestra.

La distribución Poisson se utiliza para modelar eventos poco frecuentes.

La distribución hipergeométrica se aplica cuando se seleccionan elementos sin reemplazo, como en el caso de muestras de población.

La distribución normal muestra cómo se comportan los datos alrededor de la media, permitiendo observar la forma general de la distribución.

El valor Z indica qué tan lejos se encuentra un dato respecto a la media, en este caso el valor analizado se encuentra ligeramente por debajo del promedio.

✓ Índices Estadísticos

Los índices estadísticos permiten comparar el comportamiento de los datos en distintos periodos de tiempo.

En este proyecto se calcularon:

- Índice Laspeyres
- Índice Paasche
- Índice Fisher

Estos índices ayudan a analizar cambios en la población entre diferentes años.

```
print("\n=====")
print("ÍNDICES ESTADÍSTICOS")
print("=====")

base = df["2023"]
actual = df["2024"]

# Índice Laspeyres
laspeyres = ((actual * base).sum() / (base * base).sum()) * 100

# Índice Paasche
paasche = ((actual * actual).sum() / (base * actual).sum()) * 100

# Índice Fisher
fisher = math.sqrt(laspeyres * paasche)

print("Índice Laspeyres:", laspeyres)
print("Índice Paasche:", paasche)
print("Índice Fisher:", fisher)

# Gráfica
plt.figure(figsize=(7,5))


plt.bar(
    ["Laspeyres", "Paasche", "Fisher"],
    [laspeyres, paasche, fisher]
)

plt.title("Índices Estadísticos")
plt.ylabel("Valor")

plt.savefig("indices.png")
```

```
plt.show()
```

```
=====
ÍNDICES ESTADÍSTICOS
=====
Índice Laspeyres: 99.8345988533229
Índice Paasche: 99.83946900654631
Índice Fisher: 99.83703390023823
```



Conclusión

En este proyecto se aplicaron los principales conceptos de la materia de Estadística I utilizando datos reales de población de la República Checa.

Se utilizaron herramientas de Python para limpiar los datos, calcular medidas estadísticas y generar gráficas que permitieron interpretar los resultados de manera visual.

Las medidas de tendencia central mostraron que existen valores altos que influyen en el promedio, mientras que las medidas de dispersión evidenciaron una gran variabilidad en los datos.

Las probabilidades y distribuciones permitieron analizar diferentes escenarios dentro de la población, y los índices estadísticos ayudaron a comparar el comportamiento de los datos entre distintos años.

En general, el proyecto permitió comprender cómo aplicar la estadística en situaciones reales, facilitando el análisis y la toma de decisiones basadas en datos.