

UNIVERSIDAD DE GUADALAJARA
Centro Universitario de Ciencias Económico Administrativas
CUCEA

Proyecto Final de Estadística

Estadística I

Análisis Estadístico de Proyecciones de Población de la República Checa

Alumna: Frida Suárez De Luna

Profesor: Rigoberto Silva Robles

Fecha: Mayo 2026

Índice

1. Introducción	3
2. Carga y limpieza de datos	3
3. Medidas de Tendencia Central	3
3.1. Media	3
3.2. Mediana	3
3.3. Moda	4
4. Medidas de Dispersión	4
4.1. Rango	4
4.2. Rango intercuartílico	4
4.3. Varianza	5
4.4. Desviación estándar	5
4.5. Desviación media	5
5. Introducción a Probabilidad	6
6. Distribución de Probabilidad con VAD	6
7. Distribución de Probabilidad con VAC	7
8. Datos Agrupados	7
8.1. Moda en datos agrupados	7
8.2. Mediana en datos agrupados	7
8.3. Media en datos agrupados	7
9. Datos No Agrupados	7
9.1. Moda en datos no agrupados	7
9.2. Mediana en datos no agrupados	7
9.3. Media en datos no agrupados	8
10. Diagrama de Venn	8
11. Conteo	8
12. Combinación	8
13. Permutación	8
14. Probabilidad Condicional	9
15. Teorema de Bayes	9
16. Distribución Binomial	10
17. Distribución Poisson	10
18. Distribución Hipergeométrica	10

19.Distribución Normal	11
20.Distribución Normal Estándar	12
21.Índice Paasche	12
22.Índice Laspeyres	12
23.Índice Fisher	12
24.Conclusión	13

1. Introducción

En este proyecto se realizó un análisis estadístico de datos poblacionales correspondientes a la República Checa. Para ello se utilizó Python como herramienta principal de procesamiento de datos, cálculo estadístico y generación de gráficas.

El objetivo del trabajo fue aplicar los temas vistos en Estadística I, incluyendo medidas de tendencia central, medidas de dispersión, probabilidad, distribuciones de probabilidad, conteo, combinaciones, permutaciones e índices estadísticos.

Los datos fueron organizados y limpiados mediante Python, posteriormente se calcularon los resultados y se generaron gráficas que permiten interpretar visualmente el comportamiento de la población.

2. Carga y limpieza de datos

Primero se cargó el archivo de Excel con las proyecciones de población. Después se identificó la fila donde comenzaba la tabla real, se eliminaron columnas innecesarias y se convirtieron los valores numéricos para poder realizar los cálculos.

Este paso fue importante porque permitió trabajar con una base limpia y organizada.

3. Medidas de Tendencia Central

Las medidas de tendencia central permiten identificar valores representativos dentro de un conjunto de datos.

3.1. Media

La media representa el promedio de los datos.

$$\bar{x} = \frac{\sum x_i}{n}$$

Resultado obtenido:

$$\bar{x} = 1,236,097,17$$

La media indica que el promedio de población en los datos analizados es aproximadamente de 1,236,097 personas. Este valor se ve elevado por los grupos con poblaciones más grandes.

3.2. Mediana

La mediana es el valor central cuando los datos están ordenados.

Resultado obtenido:

$$Mediana = 437,400$$

Esto significa que la mitad de los valores se encuentra por debajo de 437,400 y la otra mitad por encima.

3.3. Moda

La moda es el valor que aparece con mayor frecuencia.
Resultado obtenido:

$$Moda = 62,698$$

La moda indica que existen valores pequeños que se repiten o aparecen con mayor frecuencia dentro del conjunto de datos.




Figura 1: Media, mediana y moda

4. Medidas de Dispersión

Las medidas de dispersión permiten conocer qué tan separados están los datos respecto a un valor central.

4.1. Rango

El rango mide la diferencia entre el valor máximo y el valor mínimo.

$$Rango = X_{max} - X_{min}$$

Resultado:

$$Rango = 10,970,708$$

El rango muestra que existe una diferencia amplia entre los grupos poblacionales más pequeños y los más grandes.

4.2. Rango intercuartílico

El rango intercuartílico mide la dispersión del 50 % central de los datos.

$$RIQ = Q_3 - Q_1$$

Resultado:

$$RIQ = 641,764,5$$

Este resultado indica que la parte central de los datos todavía presenta una variación considerable.

4.3. Varianza

La varianza mide la dispersión promedio de los datos respecto a la media.

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

Resultado:

$$s^2 = 3,718,297,922,790,28$$

La varianza es alta porque los datos poblacionales tienen diferencias grandes entre grupos.

4.4. Desviación estándar

La desviación estándar indica cuánto se alejan los datos del promedio.

$$s = \sqrt{s^2}$$

Resultado:

$$s = 1,928,288,86$$

Esto significa que los valores pueden alejarse de la media en aproximadamente 1.9 millones de personas.

4.5. Desviación media

La desviación media mide el promedio de las distancias absolutas respecto a la media.

$$DM = \frac{\sum |x_i - \bar{x}|}{n}$$

Resultado:

$$DM = 1,251,769,54$$

La desviación media confirma que existe una dispersión importante entre los valores analizados.




Figura 2: Histograma de población




Figura 3: Boxplot de dispersión

5. Introducción a Probabilidad

La probabilidad permite medir la posibilidad de que ocurra un evento. En este proyecto se utilizó para calcular la posibilidad de seleccionar personas pertenecientes a determinados grupos de edad.

$$P(A) = \frac{\text{casos favorables}}{\text{casos totales}}$$

6. Distribución de Probabilidad con VAD

Una variable aleatoria discreta toma valores contables. En este proyecto se aplicó en distribuciones como la binomial, Poisson e hipergeométrica.

Ejemplo: seleccionar una cantidad específica de personas menores de cierta edad dentro de una muestra.

7. Distribución de Probabilidad con VAC

Una variable aleatoria continua puede tomar valores dentro de un intervalo. En este proyecto se relaciona con la distribución normal, ya que analiza el comportamiento de los datos alrededor de la media.

8. Datos Agrupados

Los datos agrupados permiten organizar la información en intervalos o categorías para facilitar su análisis.

8.1. Moda en datos agrupados

La moda en datos agrupados representa el intervalo con mayor frecuencia.

En este caso, los grupos de edad con mayor concentración permiten identificar dónde se ubican los valores más frecuentes.

8.2. Mediana en datos agrupados

La mediana en datos agrupados permite ubicar el punto central de la distribución considerando frecuencias acumuladas.

8.3. Media en datos agrupados

La media en datos agrupados se calcula usando los puntos medios de los intervalos y sus frecuencias.

$$\bar{x} = \frac{\sum f_i x_i}{\sum f_i}$$

9. Datos No Agrupados

Los datos no agrupados se trabajan directamente como aparecen en la base de datos, sin formar intervalos.

9.1. Moda en datos no agrupados

La moda fue:

62,698

Este valor representa el dato más frecuente.

9.2. Mediana en datos no agrupados

La mediana fue:

437,400

Este valor divide los datos en dos partes iguales.

9.3. Media en datos no agrupados

La media fue:

$$1,236,097,17$$

Este resultado representa el promedio general de los datos.

10. Diagrama de Venn

El diagrama de Venn se utiliza para representar relaciones entre eventos. En este proyecto los eventos fueron:

A = personas de 4 años o menos

B = personas menores de 10 años

Como el evento A está contenido dentro del evento B , se puede interpretar que todas las personas de 4 años o menos pertenecen también al grupo de menores de 10 años.

11. Conteo

El conteo permite determinar el número de formas posibles en que puede ocurrir un evento.

En el proyecto se utilizó el conteo para trabajar con muestras de población, por ejemplo al seleccionar 1000 personas.

$$n = 1000$$

12. Combinación

La combinación permite seleccionar elementos sin importar el orden.

$$C(n, r) = \frac{n!}{r!(n-r)!}$$

En el proyecto se relaciona con la selección de personas dentro de una muestra, donde el orden de selección no importa.

13. Permutación

La permutación permite ordenar elementos cuando el orden sí importa.

$$P(n, r) = \frac{n!}{(n-r)!}$$

Aunque en el análisis poblacional el orden no fue el elemento principal, el concepto se incluyó como parte del estudio de conteo.

14. Probabilidad Condicional

La probabilidad condicional calcula la probabilidad de que ocurra un evento sabiendo que otro ya ocurrió.

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Resultados:

$$P(A) = 0,0490$$

$$P(B) = 0,4166$$

$$P(A|B) = 0,1177$$

Esto significa que, dentro del grupo de menores de 10 años, la proporción de personas de 4 años o menos es aproximadamente 11.77 %.




Figura 4: Probabilidades calculadas

15. Teorema de Bayes

El teorema de Bayes permite actualizar una probabilidad considerando información previa.

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

En este proyecto se utilizó para interpretar la relación entre el grupo de personas de 4 años o menos y el grupo de menores de 10 años.

Resultado:

$$P(A|B) = 0,1177$$

16. Distribución Binomial

La distribución binomial se utiliza cuando existen dos resultados posibles: éxito o fracaso.

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

Datos utilizados:

$$n = 1000$$

$$p = 0,4166$$

$$k = 416$$

Resultado:

$$P(X = 416) = 0,02556$$

La interpretación es que existe una probabilidad aproximada de 2.56 % de obtener exactamente 416 personas del grupo definido en una muestra de 1000.

17. Distribución Poisson

La distribución Poisson modela eventos poco frecuentes.

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

Datos:

$$\lambda = 0,0490$$

$$k = 1$$

Resultado:

$$P(X = 1) = 0,04672$$

Esto representa la probabilidad de que ocurra una vez el evento analizado bajo una tasa pequeña.

18. Distribución Hipergeométrica

La distribución hipergeométrica se utiliza cuando se extraen elementos sin reemplazo.

$$P(X = x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}}$$

Datos:

$$N = 5,642,582$$

$$K = 276,925$$

$$n = 1000$$

$$x = 50$$

Resultado:

$$P(X = 50) = 0,05727$$

La probabilidad de seleccionar exactamente 50 personas de 4 años o menos en una muestra de 1000 es aproximadamente 5.73 %.

19. Distribución Normal

La distribución normal permite representar datos continuos alrededor de la media.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Datos:

$$\mu = 1,236,097,17$$

$$\sigma = 1,928,288,86$$




Figura 5: Distribución normal

La curva muestra cómo se comportan los datos alrededor de la media. Debido a la dispersión alta, la curva se extiende ampliamente.

20. Distribución Normal Estándar

La distribución normal estándar transforma un valor en puntaje Z .

$$z = \frac{x - \mu}{\sigma}$$

Con:

$$x = 500,000$$

Resultado:

$$z = -0,3817$$

Esto indica que el valor 500,000 se encuentra aproximadamente 0.38 desviaciones estándar por debajo de la media.

21. Índice Paasche

El índice Paasche utiliza valores del periodo actual como referencia.

$$P = \frac{\sum P_1 Q_1}{\sum P_0 Q_1} \times 100$$

Resultado:

$$99,8394$$

Este valor indica una ligera disminución respecto al año base.

22. Índice Laspeyres

El índice Laspeyres utiliza valores del periodo base como referencia.

$$L = \frac{\sum P_1 Q_0}{\sum P_0 Q_0} \times 100$$

Resultado:

$$99,8345$$

El resultado menor a 100 muestra una ligera reducción en la comparación entre años.

23. Índice Fisher

El índice Fisher es la media geométrica entre Paasche y Laspeyres.

$$F = \sqrt{P \times L}$$

Resultado:

$$99,8370$$

Este índice confirma una disminución ligera en el comportamiento poblacional comparado.




Figura 6: Índices Paasche, Laspeyres y Fisher

24. Conclusión

El proyecto permitió aplicar los temas principales de Estadística I utilizando datos reales de población de la República Checa. Mediante Python se logró limpiar la base de datos, calcular medidas estadísticas, aplicar probabilidades, trabajar con distribuciones y generar gráficas.

Los resultados muestran que los datos tienen una dispersión considerable, ya que la media es mayor que la mediana y existen diferencias importantes entre los valores mínimos y máximos. Las probabilidades permitieron analizar grupos específicos de edad, mientras que las distribuciones ayudaron a modelar escenarios estadísticos.

Finalmente, los índices Paasche, Laspeyres y Fisher permitieron comparar el comportamiento de la población entre años. El uso de LaTeX permitió presentar el trabajo de manera ordenada y profesional.